

Rzucając Wyzwanie Paradygmatowi „Większy Znaczy Lepszy”



SKALOWANIE /
BRUTALNA SIŁA

Kontekst: Wielkie modele językowe, takie jak GPT-3 (175 mld parametrów), wykazują zdolność do generalizacji zero-shot.

Wpływowa hipoteza głosi, że jest to **niejawny (implicit)** efekt uboczny ich treningu.

Centralne pytanie pracy: Czy generalizację zero-shot można zamiast tego wywołać bezpośrednio poprzez **jawny (explicit)**, wielozadaniowy trening?

Kluczowa teza: Mniejszy model, precyjnie dostrojony na mieszancę wielu zadań, może przewyższyć wydajnością modele nawet 16x większe. To demonstracja, że inteligentny trening, a nie sama skala, jest kluczem do zaawansowanych zdolności AI.



TRENING
WIELOZADANIOWY
/ FINEZJA

W tej prezentacji:

Nowa Filozofia: Jak jawny trening wielozadaniowy odblokowuje prawdziwą generalizację.

Przełomowe Dowody: Porównanie wydajności T0 z gigantami w branży.

Nowa Ścieżka: Implikacje dla bardziej wydajnego i dostępnego rozwoju AI.

Problem: Chaotyczne i Niezamierzone Uczenie Się

Cel: Uogólnienie Zero-Shot (Zero-Shot Generalization)

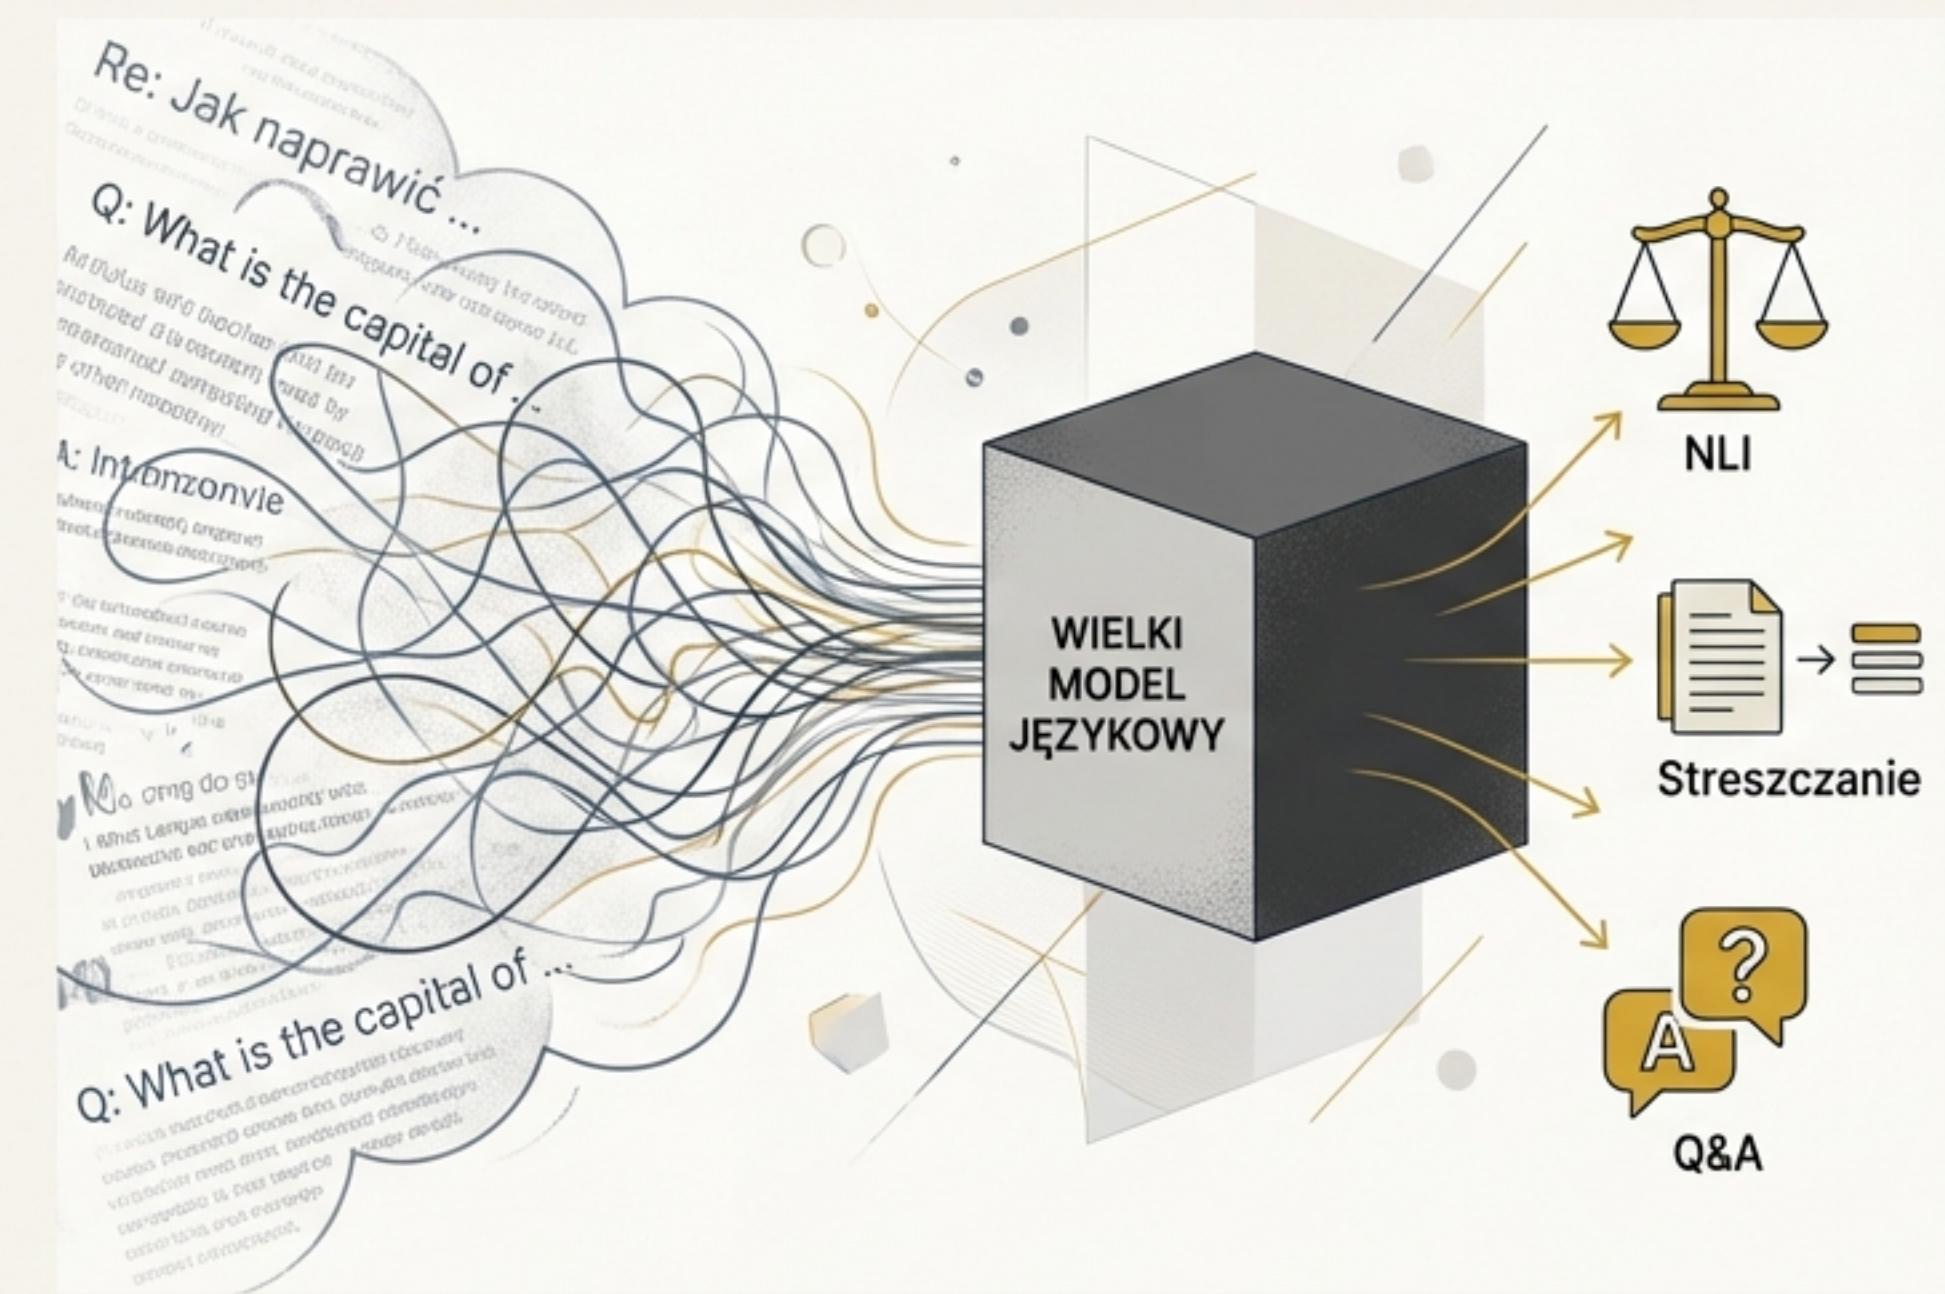
Zdolność modelu do wykonywania zadań, na których *nigdy* nie był jawnie trenowany.

- **Analogia:** Osoba, która nauczyła się czytać, potrafi nagle streszczać teksty lub pisać wiersze bez formalnego szkolenia w tych konkretnych dziedzinach.

Tradycyjne podejście: Niewjawne uczenie wielozadaniowe (Implicit Multitask Learning)

W wielkich modelach zdolność ta pojawia się jako **produkt uboczny** uczenia się przewidywania następnego słowa na ogromnych zbiorach danych z internetu.

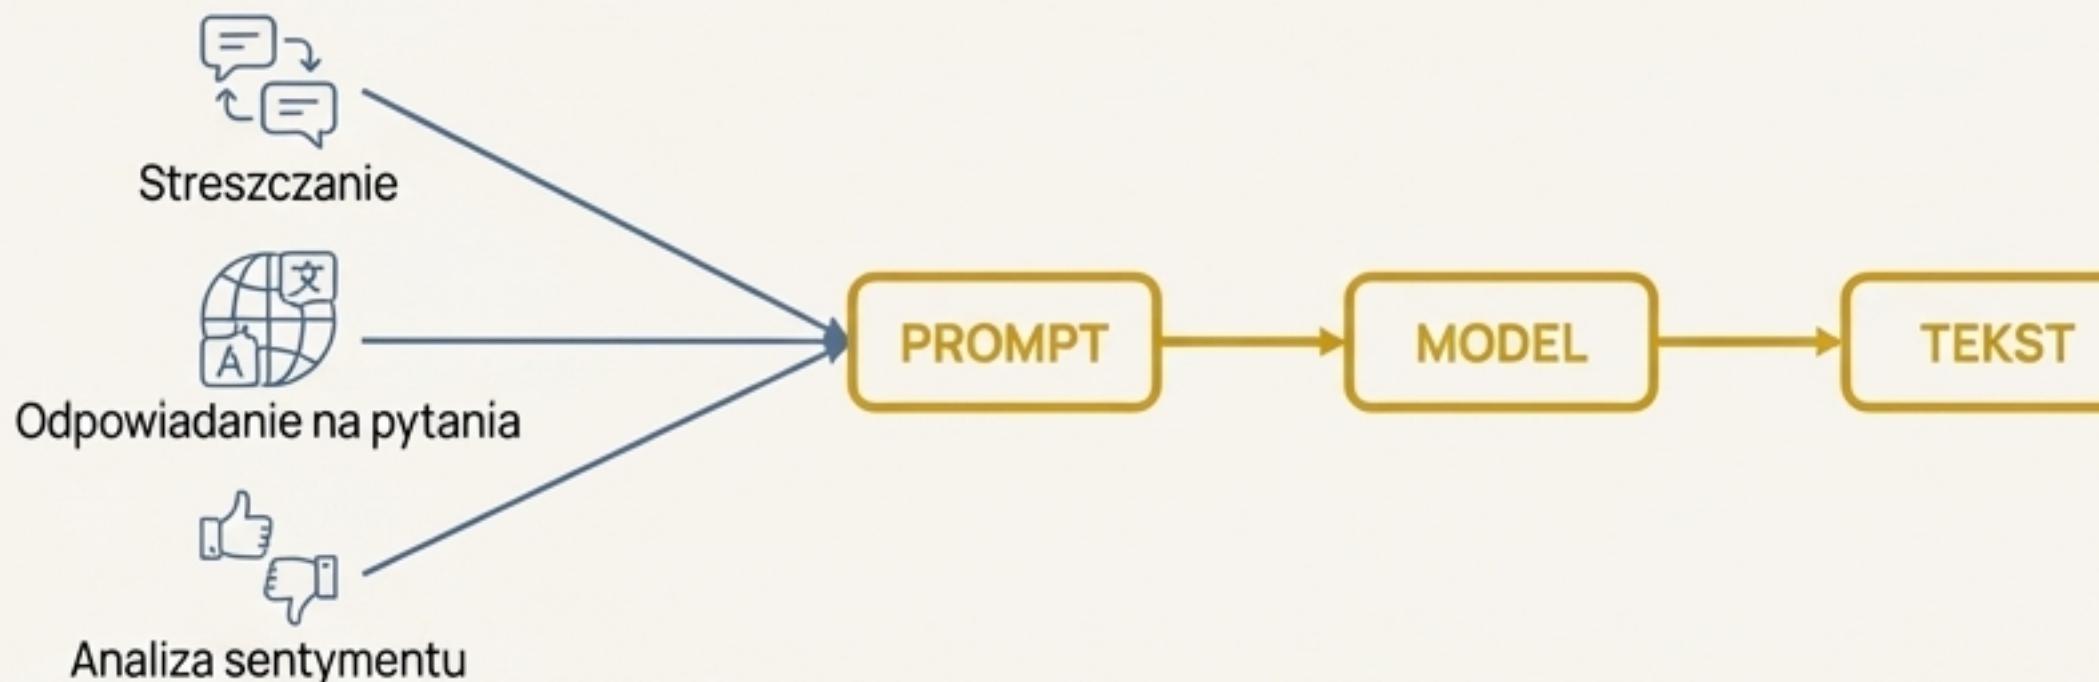
- Model uczy się formatów Q&A czy streszczeń **przypadkowo**, napotykając takie wzorce na forach internetowych czy w artykułach.
- **Problem:** To uczenie jest niekontrolowane i wymaga astronomicznej skali. Jest również wrażliwe na dokładne sformułowanie promptów.
- **Pytanie autorów TO:** A co, jeśli nie pozostawimy tej kluczowej zdolności przypadkowi?



Metodologia: Wielozadaniowy Trening na Promptach

Centralna hipoteza: Jawny, nadzorowany trening na zróżnicowanej mieszance zadań bezpośrednio buduje zdolność uogólniania zero-shot.

Kluczowa innowacja: Ujednolicony format **Text-to-Text**. Wszystkie zadania NLP – niezależnie od ich natury – są konwertowane do jednego, spójnego formatu: **tekst na wejściu → tekst na wyjściu**.



| Zadanie | Wejście (Prompt + Dane) | Wyjście |
|-------------------------|--|----------------|
| Streszczenie | „Jak streszczyć ten artykuł w kilku słowach? [artykuł]” | [streszczenie] |
| Odpowiadanie na pytania | „Wiem, że odpowiedź jest w tekście: [kontekst]. Powiedz mi: [pytanie]” | [odpowiedź] |
| Analiza sentymentu | „Na skali 1-5, dałbym tej recenzji: [recenzja]” | 4 |

Prompty stają się uniwersalnym interfejsem, który precyzyjnie definiuje zadanie.

Obietnica: Stworzenie modeli, które są **mniejsze, bardziej wydajne i odporne na zmiany w formułowaniu promptów**.

Arsenał: PromptSource i Zbiór Promptów P3

Skuteczność metody zależy od jakości i różnorodności promptów. Dlatego w ramach projektu BigScience stworzono dwa kluczowe zasoby:

1. PromptSource:

- Narzędzie open-source do wspólnego tworzenia i kolekcjonowania promptów.
- Bezprecedensowa współpraca naukowa: **36 autorów z 24 instytucji w 8 krajach.**

2. P3 (Public Pool of Prompts):

- Ogromny i niezwykle zróżnicowany zbiór promptów stworzonych przez ludzi.
- **Wiele wariantów dla każdego zadania:** od formalnych i technicznych po potoczne, kreatywne, a nawet „dziwaczne”.

Przykład: Wykrywanie parafrazy (Quora Question Pairs)

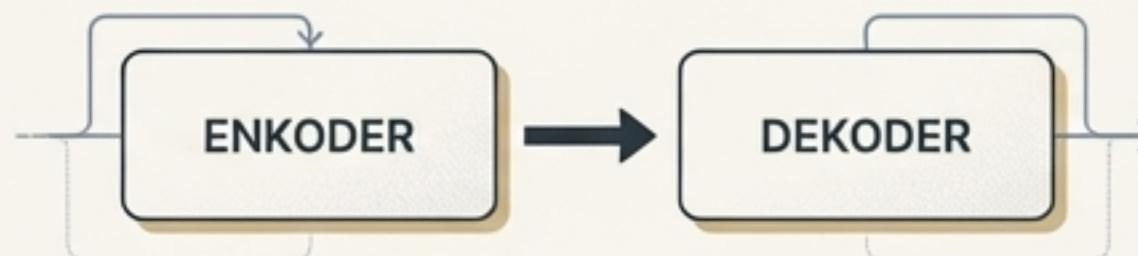
| Prompt Formalny | Prompt Kreatywny / Scenariuszowy |
|---|--|
| „Czy zdanie A oznacza to samo co zdanie B?” | „Jestem administratorem na Quorze. Są dwa posty... Czy mogę je połączyć, bo pytają o to samo?” |

Wniosek: Różnorodność i kreatywność ludzkich promptów to jakościowa przewaga, której nie da się zautomatyzować.



**Sprawdzony Silnik, Nowy Program Treningowy*

Filozofia T0 nie polegała na budowie nowego, gigantycznego silnika od zera. Zamiast tego, wzięto sprawdzoną architekturę i poddano ją rewolucyjnemu programowi treningowemu.



Model bazowy: T5+LM (LM-adapted T5)
Parametry: 11 miliardów

Stage 1: Model Bazowy



Model bazowy: T5+LM.
Sprawdzona, solidna architektura enkoder-dekoder.



The quick brown fox jumps over the [MASK] dog.

Stage 2: Pre-trening MLM

Metoda pre-treningu: Masked Language Modeling (MLM).
Kluczowa przewaga: Jak wykazano w pracy, MLM jest „dramatycznie bardziej efektywną strategią pre-treningu” dla zadań fine-tuningu.



Stage 3: Fine-tuning na P3

Podejście treningowe: Dostrajanie (fine-tuning) na ogromnej, zróżnicowanej mieszance promptów ze zbioru P3.

Moment przełomu

Rezultaty: Dawid Pokonuje Goliata

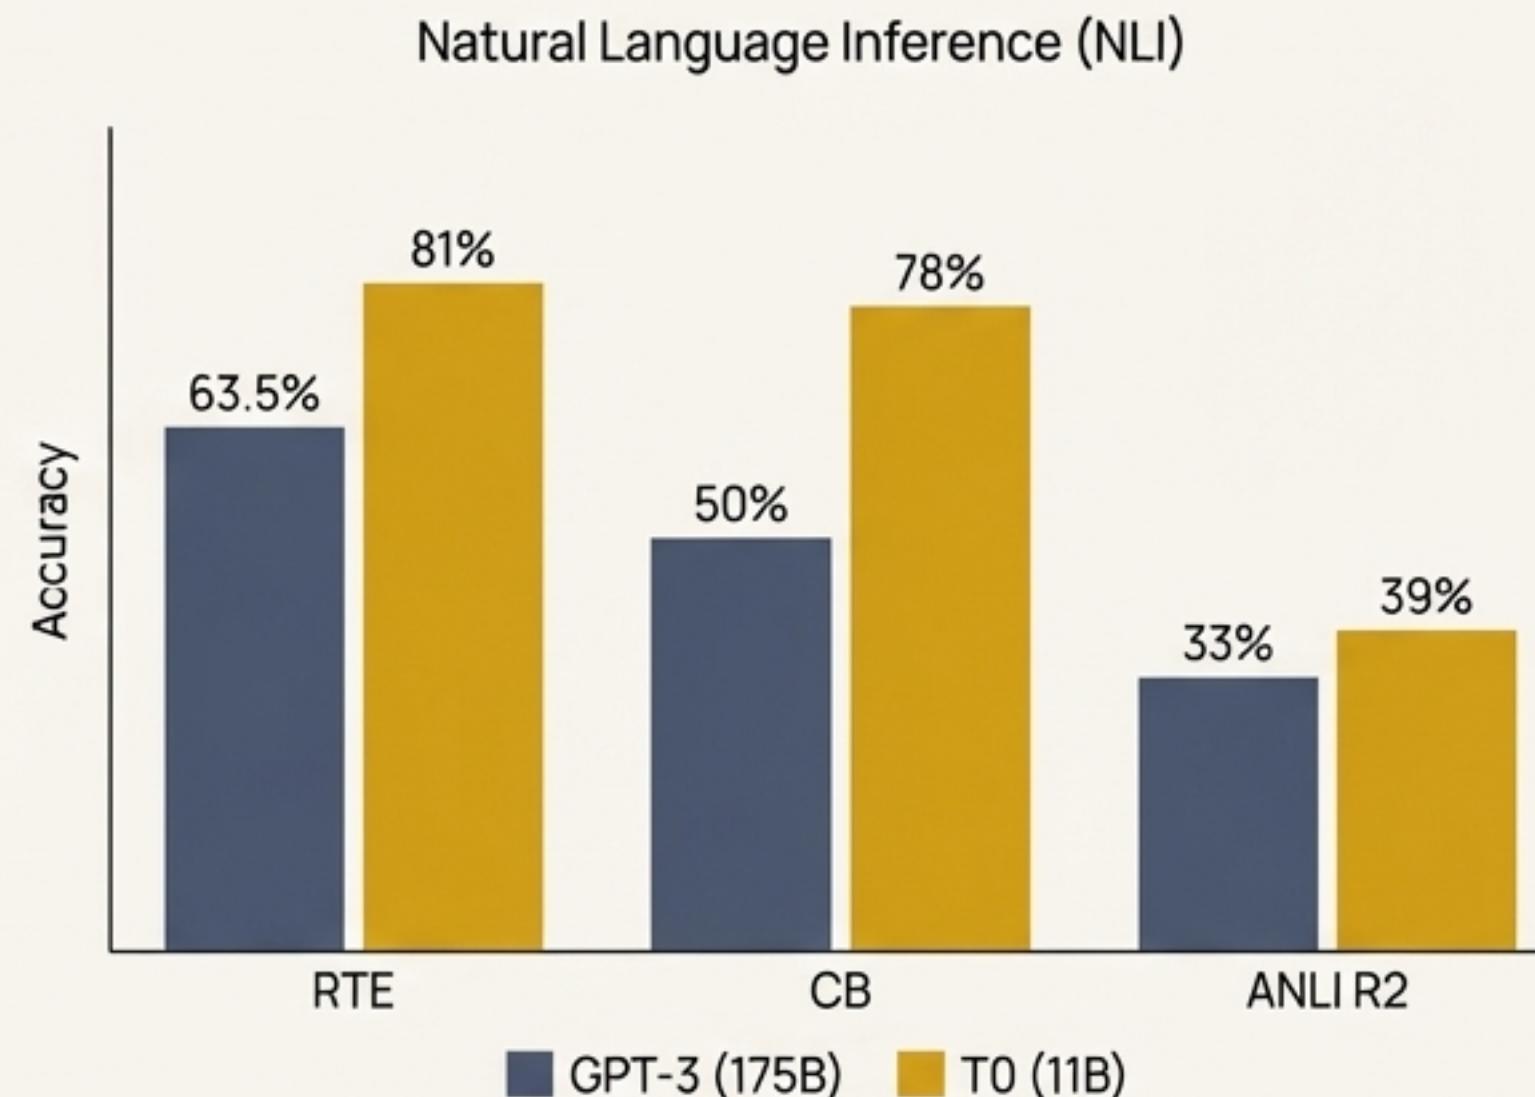
T0 (11 mld parametrów) uzyskał lepsze lub porównywalne wyniki co **GPT-3** (175 mld parametrów) na **9 z 11 zadań testowych** (held-out tasks), na których żaden z modeli **nie był wcześniej trenowany**.

**16X
MNIEJSZY**

T0 (11B) vs GPT-3 (175B)

SIŁA W NLI
(Natural Language Inference)

Szczególnie dobre wyniki w zadaniach wymagających logicznego rozumowania, co dowodzi głębszego zrozumienia języka.



**9 z 11
WYGRANYCH ZADAŃ**
w trybie zero-shot

**WYNIKI NA
BIG-BENCH**

T0 pokonał modele nawet 6x większe od siebie.

To nie jest tylko usprawnienie. To dowód na istnienie **alternatywnej, bardziej efektywnej ścieżki** do budowania zaawansowanej AI.

Odporność na Prompty: Głębia > Szerokość

Czy sukces T0 zależał od znalezienia jednego „złotego promptu”? Analiza pokazuje, że wręcz przeciwnie – jego siła leży w odporności na ich różnorodność.

Kluczowe wnioski z analizy:

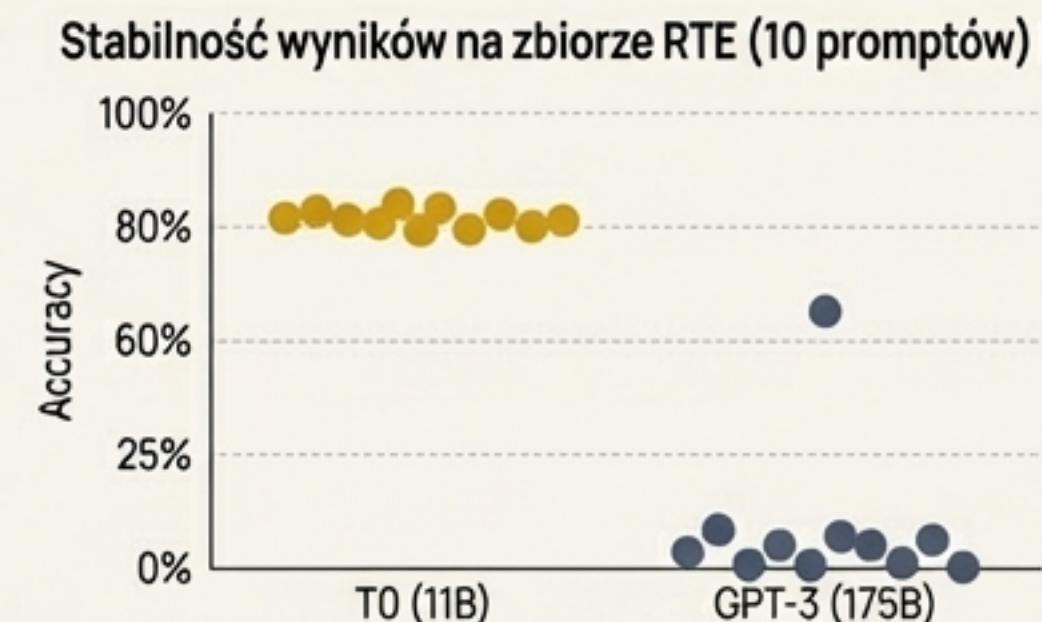
- Wniosek 1 (Głębia):** Trening na większej liczbie wariantów promptów na zadanie prowadzi do **lepszych i bardziej stabilnych wyników** (niższa wariancja).
- Wniosek 2 (Szerokość):** Zwiększanie liczby zadań poprawia medianę, ale niekoniecznie stabilność.

Głębia (warianty promptów) jest ważniejsza dla odporności niż Szerokość (liczba zadań).

Dowód: Porównanie na zbiorze RTE

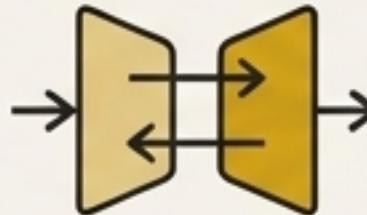
W teście na 10 różnych promptach dla zadania RTE:

- GPT-3:** Ekstremalnie wrażliwy. Dobre wyniki osiągnął **tylko dla jednego promptu**. Pozostałe 9 dały wyniki na poziomie losowym.
- T0:** Solidne, powtarzalne wyniki na **wielu różnych sformułowaniach tego samego zadania**.



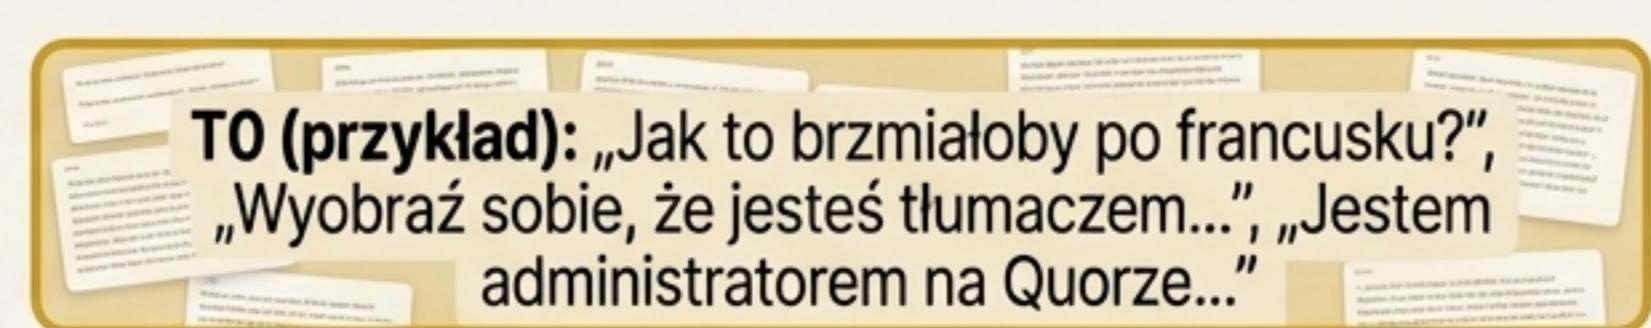
Porównanie z FLAN: Przewaga w Różnorodności

FLAN (Google): Podobna koncepcja opublikowana w tym samym czasie. Również wykorzystuje trening wielozadaniowy. **Mimo to, T0 i T0++ osiągnęły porównywalne lub lepsze wyniki, będąc ponad 10x mniejszymi modelami (11B vs 137B FLAN).** Dlaczego?

| Cecha | T0 (Hugging Face / BigScience) | FLAN (Google) |
|-----------------------|--|---|
| Architektura |  Enkoder-Dekoder (pre-trening MLM) |  Dekoder-Only |
| Różnorodność Promptów |  Ogromna: Średnio 8+ ręcznie tworzonych, kreatywnych wariantów na zadanie z P3. |  Ograniczona: ok. 10 szablonów, głównie generowanych automatycznie. |

Różnorodność ma znaczenie:

FLAN (przykład): „Przetłumacz to zdanie na francuski.”



T0 (przykład): „Jak to brzmiałoby po francusku?”, „Wyobraź sobie, że jesteś tłumaczem...”, „Jestem administratorem na Quorze...”

Wniosek: Przewaga T0 wynika nie tylko z architektury, ale przede wszystkim z **niezastąpionej, ludzkiej kreatywności** w tworzeniu promptów, która prowadzi do głębszego i bardziej elastycznego zrozumienia zadań.

Nowa mapa drogowa dla AI

Implikacje: Od Brutalnej Siły do Inteligentnego Rozwoju

Praca nad T0 to więcej niż tylko kolejny model – to dowód na istnienie nowej filozofii rozwoju AI.

- 1. Alternatywna Ścieżka Rozwoju:** Inteligentny trening nadzorowany staje się realną alternatywą dla brutalnej siły skalowania. Koniec z dogmatem „bigger is better”.
- 2. Korzyści Środowiskowe i Kosztowe:** Lepsze wyniki bez potrzeby astronomicznych zasobów obliczeniowych.
“Szacowana emisja CO₂: Trening wszystkich modeli T0 to ok. 8.9 tCO₂e, w porównaniu do 46.7 tCO₂e dla samego pre-treningu T5-11B.”
- 3. Demokratyzacja Badań:** Otwarty charakter projektu BigScience oraz publiczne udostępnienie modeli, promptów (P3) i narzędzi (**PromptSource**) umożliwia mniejszym zespołom badawczym prowadzenie zaawansowanych badań.
- 4. Zmiana Perspektywy:** Przesunięcie fokусу z „hodowania” coraz większych, nieprzewidywalnych modeli na rzecz świadomego „wychowywania” agentów z konkretnymi, weryfikowalnymi umiejętnościami.



BRUTALNA SIŁA



INTELIGENTNY ROZWÓJ

T0: Początek Nowej Ery w Otwartej Nauce o AI

Główne Przesłanie: Finezja > Siła

Inteligentne projektowanie danych treningowych i wykorzystanie ludzkiej kreatywności w tworzeniu promptów jest potężniejszą i bardziej efektywną dźwignią postępu niż samo bezrefleksywne zwiększanie liczby parametrów.

Dołącz do rewolucji:

Praca nad T0 została przeprowadzona w ramach otwartej inicjatywy BigScience. Wszystkie zasoby są publicznie dostępne, aby umożliwić dalsze badania i rozwój:



Modele T0:

github.com/bigscience-workshop/t-zero



Zbiór Promptów (P3) i Narzędzie (PromptSource):

github.com/bigscience-workshop/promptsource

T0 nie jest końcem drogi. To zaproszenie dla całej społeczności do wspólnego budowania przyszłości AI – bardziej inteligentnej, wydajnej i dostępnej dla wszystkich.